

# Notas de Econometría

Pavel Solís  
2025

## 1 Modelo de Regresión Lineal Simple (RLS)

El modelo explica una variable en términos de otra

- El álgebra y la interpretación del modelo son relativamente sencillas
- Permite cubrir temas importantes de forma aislada
  - Cambios en unidades de medición, efectos no lineales

### 1.1 Definición del modelo

$y$  y  $x$  son 2 variables que representan alguna población

- Queremos explicar  $y$  en términos de  $x$

Preguntas que debemos responder:

- ¿Cómo permitimos que otros factores afecten a  $y$  si la relación no es exacta?
- ¿Cuál es la forma funcional de la relación entre  $x$  y  $y$ ?
- ¿Cómo sabemos si capturamos una relación ceteris paribus entre  $x$  y  $y$ ?

Empezamos con una ecuación simple para capturar la relación:

$$y = \beta_0 + \beta_1 x + u$$

- Suponemos que la ecuación se cumple en la población

La ecuación se conoce como:

- Modelo de **regresión lineal simple** (RLS)
- Modelo de regresión lineal de 2 variables
- Modelo de regresión lineal bivariado

La variable  $y$  se conoce como variable:

- **dependiente**
- explicada
- de respuesta
- predicha
- regresada

La variable  $x$  se conoce como variable:

- **independiente**
- explicativa
- de control
- predictor o predictiva
- **regresor**
- covariable

Los **parámetros** son  $\beta_0$  y  $\beta_1$

- $\beta_0$  es el parámetro del intercepto o la **constante** (rara vez es de interés)
- $\beta_1$  es el parámetro de la **pendiente** (interés principal)

La variable  $u$ :

- Se conoce como el **término de error** o de perturbación
- Captura todos los factores no observados distintos a  $x$  que afectan a  $y$
- Ej.  $y = \text{salario}$ ,  $x = \text{educ}$ ,  $u = \text{experiencia, habilidad, antigüedad, ética laboral, ...}$

La relación expresada en cambios es:

$$\Delta y = \beta_1 \Delta x + \Delta u$$

Si los factores en  $u$  se mantienen fijos,

$$\Delta u = 0 \implies \Delta y = \beta_1 \Delta x$$

- $x$  tiene un efecto lineal en  $y$ 
  - Mismo efecto en  $y$  sin importar el valor inicial de  $x$

¿Cómo sabemos el efecto ceteris paribus de  $x$  sobre  $y$  si ignoramos todos los otros factores?

- Necesitamos hacer un supuesto para restringir la relación entre  $x$  y  $u$ 
  - Usamos conceptos de probabilidad porque  $x$  y  $u$  son variables aleatorias
- Un supuesto poco restrictivo es

$$\mathbb{E}(u) = 0$$

- Siempre podemos redefinir el intercepto  $\beta_0$  para esto
- Posibilidades para que  $\mathbb{E}(u) = 0$ :
  - Suponer que  $u$  y  $x$  no están correlacionadas
    - \* No es útil porque solo mide dependencia lineal
  - Definir una distribución condicional de  $u$  dado  $x$

- Supuesto clave:

$$\mathbb{E}(u|x) = \mathbb{E}(u)$$

- Dice que  $u$  es independiente en media de  $x$
- El valor esperado de  $u$  no depende de  $x$  y es igual al promedio de  $u$  para toda la población
- Combinando ambos supuestos, obtenemos el supuesto de **media condicional cero**

$$\mathbb{E}(u|x) = 0$$

- Ej.  $\mathbb{E}(\text{habilidad}|8) = \mathbb{E}(\text{habilidad}|6)$
- El supuesto de media condicional cero da una nueva interpretación para  $\beta_1$

La **función de regresión de la población** (FRP) es:

$$\mathbb{E}(y|x) = \mathbb{E}(\beta_0 + \beta_1 x + u|x) = \beta_0 + \beta_1 x$$

- *Promedio* de  $y$  (no la  $y$  que varía con  $u$ ) es una función lineal de  $x$ 
  - Si  $\Delta x = 1$ ,  $\mathbb{E}(y)$  sube en  $\beta_1$

[Gráfica]

## 1.2 Derivación de los estimadores de MCO

Observamos  $x$  y  $y$ , pero no observamos  $\beta_0$ ,  $\beta_1$  ni  $u$

Podemos estimar los parámetros  $\beta_0$  y  $\beta_1$  a partir de una muestra aleatoria de la población de tamaño  $n$ ,  $\{(x_i, y_i) \mid i = 1, 2, \dots, n\}$

En la población,

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad \forall i \implies u_i = y_i - \beta_0 - \beta_1 x_i$$

- $u_i$  es el término de error de la observación  $i$ 
  - Factores que afectan a  $y_i$  distintos de  $x_i$

Con los supuestos  $\mathbb{E}(u) = 0$  y  $\mathbb{E}(u|x) = \mathbb{E}(u)$  podemos concluir que  $\text{Cov}(x, u) = 0$

$$\text{Cov}(x, u) = \mathbb{E}(xu) - \mathbb{E}(x)\mathbb{E}(u) = \mathbb{E}(xu) = 0$$

- Entonces, obtenemos 2 restricciones para la distribución de probabilidad conjunta de  $x$  y  $y$ :
  - $\mathbb{E}(u) = \mathbb{E}(y - \beta_0 - \beta_1 x) = 0$
  - $\mathbb{E}(xu) = \mathbb{E}[x(y - \beta_0 - \beta_1 x)] = 0$

Escogemos  $\hat{\beta}_0$  y  $\hat{\beta}_1$  de forma que resuelvan las versiones muestrales de esas 2 restricciones (sistema  $2 \times 2$ ):

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0 \implies \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0 \implies \sum_{i=1}^n x_i [y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i] = 0 \\ \implies \sum_{i=1}^n x_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= \sum_{i=1}^n (x_i - \bar{x}) (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \\ \implies \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x}) (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x^2} = \hat{\rho}_{xy} \frac{\hat{\sigma}_y}{\hat{\sigma}_x} \end{aligned}$$

Estos estimadores se conocen como los **estimadores de mínimos cuadrados ordinarios** (MCO)

- El nombre viene de una forma alternativa de obtener las versiones muestrales de las 2 restricciones anteriores

- Escogemos  $\hat{\beta}_0$  y  $\hat{\beta}_1$  de forma que minimicen la suma de los residuales al cuadrado  $\min \sum_{i=1}^n \hat{u}_i^2 = \min \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$
- Se obtienen las mismas condiciones de primer orden que antes
- ¿Cuál es la única condición para calcular  $\hat{\beta}_0$  y  $\hat{\beta}_1$ ?
  - Variación en  $x_i$
- Regresión simple es un análisis de correlación entre 2 variables
  - No implica causalidad
  - A veces es suficiente

Al calcular los estimados de MCO, podemos obtener 2 cosas:

- **Valores ajustados** o estimados para  $y$  cuando  $x = x_i$ :

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

- **Residuales** (no son los errores  $u_i$ ):

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

[Gráfica]

La línea de regresión de MCO es

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \implies \Delta \hat{y} = \hat{\beta}_1 \Delta x$$

- Es la **función de regresión de la muestra** (FRM), varía con cada muestra
- Versión estimada de la FRP:  $\mathbb{E}(y|x) = \beta_0 + \beta_1 x$ , fija y desconocida en la población

[Gráfica]

Ejemplo. wage1.dta

$$\widehat{\text{salar}} = -0.90 + 0.54 \text{educ}$$

- Si  $\text{educ} = 8$ ,

$$\widehat{\text{salar}} = -0.90 + 0.54(8) = 3.42$$

Terminología: Correr una regresión de  $y$  (variable dependiente) sobre  $x$  (variable independiente) para obtener  $\hat{\beta}_0$  y  $\hat{\beta}_1$

- Ej. Correr una regresión del *salar* sobre *educ*

### 1.3 Propiedades algebraicas de MCO

Estas propiedades se cumplen para cualquier muestra (por construcción)

Ayudan a entender qué le pasa a los estimados de MCO cuando manipulamos los datos

- Ej. Si cambiamos las unidades de medición

### 1.3.1 Valores ajustados y residuales

Cada valor ajustado de  $\hat{y}_i$  está sobre la línea de regresión de MCO

El residual de MCO para cada observación  $i$  es  $\hat{u}_i = y_i - \hat{y}_i$

- Generalmente,  $\hat{u}_i \neq 0$  por lo que los puntos  $y_i$  no caen sobre la línea de MCO
- Si  $\hat{u}_i > 0$ , la línea de regresión subestima  $y_i$
- Si  $\hat{u}_i < 0$ , la línea de regresión sobreestima  $y_i$

### 1.3.2 Propiedades algebraicas

1.  $\sum_{i=1}^n \hat{u}_i = 0$ 
  - Viene de la primera condición
  - $\hat{\beta}_0$  y  $\hat{\beta}_1$  son escogidos tal que la suma (y promedio) de los residuales sea cero
2.  $\sum_{i=1}^n x_i \hat{u}_i = 0$ 
  - Viene de la segunda condición
  - Equivale a  $\text{Cov}(x_i, \hat{u}_i) = 0$  porque el promedio muestral de  $\hat{u}_i$  es cero
3.  $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$ 
  - Viene de la primera condición
  - El punto  $(\bar{x}, \bar{y})$  siempre está sobre la línea de regresión de MCO

Para una interpretación alternativa, observa que MCO descompone  $y_i$  en 2 partes:

$$y_i = \hat{y}_i + \hat{u}_i$$

- $\hat{\bar{y}} = \bar{y}$  porque  $\hat{\bar{u}} = 0$
- $\text{Cov}(\hat{y}_i, \hat{u}_i) = 0$ 
  - Los valores ajustados y los residuales no están correlacionados

Podemos definir la variación de cada una de las partes:

- Suma de cuadrados total:  $\text{SCT} = \sum_{i=1}^n (y_i - \bar{y})^2$ 
  - Mide la variación total de (o qué tan dispersa está)  $y_i$  en la muestra
- Suma de cuadrados explicada:  $\text{SCE} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ 
  - Mide la variación de  $\hat{y}_i$  en la muestra
- Suma de cuadrados de los residuales:  $\text{SCR} = \sum_{i=1}^n \hat{u}_i^2$ 
  - Mide la variación de  $\hat{u}_i$  en la muestra

La variación total en  $y$  siempre se puede expresar como la suma de la variación explicada y la no explicada (porque  $\text{Cov}(\hat{y}_i, \hat{u}_i) = 0$ ):

$$\text{SCT} = \text{SCE} + \text{SCR}$$

### 1.3.3 Bondad de ajuste

Número que resume qué tan bien se ajusta la línea de regresión de MCO a los datos  
Si  $SCT \neq 0$  ( $y_i \neq c \forall i$ ),

$$1 = \frac{SCE}{SCT} + \frac{SCR}{SCT} \implies \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT} = R^2$$

- $R^2$  se conoce como el **coeficiente de determinación**
- $0 \leq R^2 \leq 1$  porque  $SCE \leq SCT$ 
  - $R^2$  es la fracción de la variación de  $y$  en la muestra explicada por  $x$
- Interpretación en porcentaje ( $100 \times R^2$ )
  - Porcentaje de variación de  $y$  en la muestra explicada por  $x$
- $R^2 \approx 0$  significa que la línea de regresión de MCO ajusta mal
  - Aún así puede llegar a ser útil

Pregunta. ¿Qué significaría una  $R^2 = 1$ ?

## 1.4 Unidades de medición y forma funcional

¿Qué le pasa a los estimados de MCO cuando manipulamos los datos?

### 1.4.1 Efectos del cambio en unidades de medición

¿Qué pasa si cambiamos las unidades de medición de las variables en el modelo RLS?  
Podemos multiplicar por una constante  $c$  a la variable dependiente o a la independiente

- Si  $\hat{y}_1 = \hat{\beta}_0 + \hat{\beta}_1 x$  y  $y_2 = cy_1$ , entonces

$$\hat{y}_2 = c\hat{\beta}_0 + c\hat{\beta}_1 x$$

- Afecta a ambos estimados

- Si  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$  y  $x_2 = \frac{x_1}{c}$ , entonces

$$\hat{y} = \hat{\beta}_0 + c\hat{\beta}_1 x_2$$

- No afecta al intercepto

$R^2$  es invariante a cambios en unidades de  $x$  o  $y$

- $R^2$  no depende de las unidades de medición

Preguntas. Una regresión del salario expresado en miles de dólares (*salarimil*) sobre el rendimiento del capital expresado en porcentaje (*roepct*) arroja lo siguiente:

$$\widehat{salarimil} = 963.191 + 18.501roepct$$

- ¿Cómo cambian los estimados si expresamos el salario en dólares (*salariodol*) (y el rendimiento del capital se queda en porcentaje, *roepct*)?
- ¿Cómo cambian los estimados si expresamos el rendimiento del capital en proporción (*roedec*) (y el salario se queda en miles de dólares, *salarimil*)?

### 1.4.2 Efectos no lineales en RLS

Hasta ahora solo hemos visto la relación lineal entre  $x$  y  $y$

- Es fácil capturar efectos no lineales si definimos apropiadamente  $x$  y  $y$

Podemos usar el logaritmo natural para capturar:

- Crecimiento porcentual constante (rendimientos crecientes)
- Elasticidad constante

#### Modelo nivel-nivel

$$y = \beta_0 + \beta_1 x + u \implies \Delta y = \beta_1 \Delta x$$

- Mismo efecto en  $y$  sin importar el valor inicial de  $x$

#### Modelo log-nivel

$$\log(y) = \beta_0 + \beta_1 x + u \implies \Delta \log(y) = \beta_1 \Delta x \implies \% \Delta y \approx (100 \times \beta_1) \Delta x$$

- Equivalente a  $y = \exp(\beta_0 + \beta_1 x + u)$   
[Gráfica]
- Captura un crecimiento porcentual constante
- Cambio en la variable dependiente crece por cada cambio *unitario* en  $x$
- $100 \times \beta_1$  se conoce como la **semi-elasticidad** de  $y$  respecto a  $x$

Pregunta. Una regresión del logaritmo del salario en dólares por hora sobre los años de educación arroja lo siguiente:

$$\log(\widehat{\text{salario}}) = 0.584 + 0.083educ$$

- ¿Cómo cambia el *salario* por cada año adicional de educación?

#### Modelo log-log o de elasticidad constante

$$\log(y) = \beta_0 + \beta_1 \log(x) + u \implies \Delta \log(y) = \beta_1 \Delta \log(x) \implies \% \Delta y \approx \beta_1 \% \Delta x$$

- $\beta_1$  se conoce como la **elasticidad** de  $y$  con respecto a  $x$

Pregunta. Una regresión del logaritmo del salario sobre el logaritmo de los ventas

arroja lo siguiente:

$$\widehat{\log(\text{salario})} = 4.822 + 0.257 \log(\text{ventas})$$

- ¿Cómo cambia el *salario* con las *ventas*?

### Modelo nivel-log (poco usado)

$$y = \beta_0 + \beta_1 \log(x) + u \implies \Delta y = \beta_1 \Delta \log(x) = \frac{\beta_1}{100} 100 \Delta \log(x) \implies \Delta y \approx \frac{\beta_1}{100} \% \Delta x$$

- $\frac{\beta_1}{100}$  es el cambio unitario en  $y$  cuando  $x$  aumenta 1%

Preguntas. Una regresión de las horas trabajadas a la semana sobre el logaritmo del salario por hora arroja lo siguiente:

$$\widehat{\text{horas}} = 33 + 45.1 \log(\text{salario})$$

- ¿Cómo cambian las horas trabajadas con un aumento de 1% en el salario?
- ¿Y si el salario aumenta en 10%?

### 1.4.3 Significado de regresión lineal

El modelo  $y = \beta_0 + \beta_1 x + u$  permite capturar relaciones no lineales entre  $x$  y  $y$

- El modelo es lineal en los parámetros  $\beta_0$  y  $\beta_1$
- No hay restricciones en cómo se definen  $x$  y  $y$ 
  - Importante: Definiciones de  $x$  y  $y$  sí afectan la interpretación
- Ej. Modelo de regresión no lineal

$$y = \frac{1}{\beta_0 + \beta_1 x} + u$$

## 1.5 Valores esperados y varianzas de los estimadores de MCO

Interesados en propiedades de los estimadores  $\hat{\beta}_0$  y  $\hat{\beta}_1$  para los parámetros  $\beta_0$  y  $\beta_1$

- Propiedades de las distribuciones muestrales (valor esperado, varianza)
- Propiedades estadísticas (falta sesgo, consistencia)

Para estudiar esas propiedades, hacemos supuestos sobre la población (modelo RLS)

- Supuestos Gauss-Markov (G-M)
  - Supuestos ideales para obtener propiedades deseables
  - Después desviaciones de esos supuestos
  - Ej. Línea de producción de una fábrica



### 1.5.1 Falta de sesgo de MCO

¿Cuál es el centro de la distribución de  $\hat{\beta}_1$ ?

Supuesto RLS.1. El modelo es lineal en parámetros

Este supuesto define el modelo poblacional

$$y = \beta_0 + \beta_1 x + u$$

- $\beta_0$  y  $\beta_1$  son los parámetros poblacionales (desconocidos)
- $x, y, u$  son variables aleatorias
- Permite capturar relaciones no lineales

Supuesto RLS.2. La muestra es aleatoria

Obtenemos una muestra aleatoria de tamaño  $n$ ,  $\{(x_i, y_i) \mid i = 1, 2, \dots, n\}$ , del modelo poblacional en RLS.1

- Usamos los datos para estimar los parámetros

El modelo poblacional en términos de la muestra aleatoria es:

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad \forall i$$

- $u_i$  son los factores no observados que afectan a  $y_i$
- $u_i \neq \hat{u}_i$

[Gráfica]

Supuesto RLS.3. Hay variación en la variable independiente en la muestra

Los valores de  $x$  en la muestra,  $\{x_i \mid i = 1, 2, \dots, n\}$ , no son todos iguales

- Se puede verificar revisando que  $\text{desvest}(x_i) \neq 0$
- Recordatorio: Los estimados de MCO para el intercepto y la pendiente están definidos solo si hay variación en la variable independiente

Supuesto RLS.4. Media condicional cero

$$\mathbb{E}(u|x) = 0$$

Todos los otros factores que afectan a  $y$  no se correlacionan con  $x$

- Para una muestra aleatoria, RLS.4 implica que  $\mathbb{E}(u_i|x_i) = 0 \quad \forall i$
- Permite obtener estimadores de  $\beta_0$  y  $\beta_1$  insesgados

Bajo supuestos RLS.1-RLS.4,  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son insesgados

- Primero definimos:  $SCT_x = \sum_{i=1}^n (x_i - \bar{x})^2$

- Reescribimos  $\hat{\beta}_1$  (variable aleatoria)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{SCT_x} = \frac{\sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i)}{SCT_x}$$

$$\hat{\beta}_1 = \frac{\beta_1 SCT_x + \sum_{i=1}^n (x_i - \bar{x}) u_i}{SCT_x} \implies \mathbb{E}(\hat{\beta}_1) = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \mathbb{E}(u_i)}{SCT_x} = \beta_1$$

- Para  $\hat{\beta}_0$ , usamos  $\bar{y} = \beta_0 + \beta_1 \bar{x}$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x} = \beta_0 + (\beta_1 - \hat{\beta}_1) \bar{x} + \bar{u}$$

$$\mathbb{E}(\hat{\beta}_0) = \beta_0 + \mathbb{E}(\beta_1 - \hat{\beta}_1) \bar{x} + \mathbb{E}(\bar{u}) = \beta_0$$

Comentarios sobre la falta de sesgo:

- Falta de sesgo depende de RLS.1-RLS.4
  - Ej. Si RLS.4 no se cumple,  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son sesgados
- En RLS siempre preocupa que  $\text{Corr}(x, u) \neq 0$ 
  - Puede resultar en correlación espuria entre  $x$  y  $y$
  - Ej. Variable omitida

### 1.5.2 Varianza de los estimadores de MCO

La distribución de  $\hat{\beta}_1$  está centrada en  $\beta_1$ , ¿qué tan dispersa es?

Supuesto RLS.5. Homocedasticidad

$$\text{Var}(u | x) = \sigma^2$$

La varianza del error no observado condicional en  $x$  es constante (**homocedasticidad**)

- Es diferente del valor esperado de  $u$  dado  $x$ :  $\mathbb{E}(u|x) = 0$
- No se utiliza para demostrar falta de sesgo
- De la definición de la varianza,

$$\text{Var}(u | x) = \mathbb{E}(u^2 | x) - [\mathbb{E}(u | x)]^2 = \mathbb{E}(u^2 | x) = \sigma^2$$

- No depende de  $x$ , entonces  $\sigma^2 = \mathbb{E}(u^2) = \text{Var}(u)$
- $\sigma^2$  es la varianza incondicional de  $u$  y se llama **varianza del error**
- $\sigma$  es la desviación estándar del error
- Si  $\text{Var}(u | x) = g(x)$ , el término de error exhibe **heterocedasticidad**
  - Varianza no constante

Podemos expresar RLS.4 y RLS.5 en términos de la media y varianza condicionales de  $y$

- RLS.4:  $\mathbb{E}(y | x) = \beta_0 + \beta_1 x$ , es lineal en  $x$
- RLS.5:  $\text{Var}(y | x) = \sigma^2$ , es constante

[Gráfica]

Las **varianzas muestrales** de los estimadores de MCO son

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\text{SCT}_x} \quad \text{y} \quad \text{Var}(\hat{\beta}_0) = \frac{\sigma^2}{n} \frac{\sum_{i=1}^n x_i^2}{\text{SCT}_x}$$

- Válidas solo bajo homocedasticidad
- Más variación en lo no observado ( $u$ ), hace más difícil estimar  $\beta_1$
- Se prefiere más varianza en  $x_i$  porque es más fácil estimar  $\beta_1$ , así como identificar la relación entre  $\mathbb{E}(y | x)$  y  $x$
- Una muestra más grande debería aumentar  $\text{SCT}_x$ 
  - Menor varianza para  $\hat{\beta}_1$

¿Por qué no podemos calcular las varianzas muestrales?

### 1.5.3 Estimación de la varianza del error

Las fórmulas de las varianzas dependen de  $\sigma^2$ , generalmente se desconoce

Podemos estimar  $\sigma^2$  para, a su vez, estimar  $\text{Var}(\hat{\beta}_0)$  y  $\text{Var}(\hat{\beta}_1)$

Importante distinguir entre:

- Modelo poblacional:  $y_i = \beta_0 + \beta_1 x_i + u_i$ 
  - Usa parámetros ( $\beta_0$  y  $\beta_1$ ) y los errores  $u_i$  nunca se observan
- Descomposición entre valores ajustados y residuales:  $y_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + \hat{u}_i$ 
  - Usa estimados ( $\hat{\beta}_0$  y  $\hat{\beta}_1$ ) y los residuales  $\hat{u}_i$  se obtienen de los datos

Podemos reescribir los residuales como función de los errores:

$$\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = (\beta_0 + \beta_1 x_i + u_i) - \hat{\beta}_0 - \hat{\beta}_1 x_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1) x_i$$

- Entonces  $\hat{u}_i \neq u_i$ , aunque  $\mathbb{E}(u_i - \hat{u}_i) = 0$

Sabemos que  $\sigma^2 = \mathbb{E}(u^2)$ , entonces un 'estimador' insesgado sería  $\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n u_i^2$

- ¿Cuál es el problema con ese estimador?

Tenemos estimados de  $u_i$  ( $\hat{u}_i$ ), entonces podríamos usar  $\check{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 = \frac{\text{SCR}}{n}$

- ¿Problema? Es sesgado
- No satisface las restricciones de los residuales de MCO:  $\sum_{i=1}^n \hat{u}_i = 0$  y  $\sum_{i=1}^n x_i \hat{u}_i = 0$
- ¿Cuántos grados de libertad hay?

Un estimador insesgado de  $\sigma^2$  es

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2 = \frac{\text{SCR}}{n-2}$$

- $\mathbb{E}(\hat{\sigma}^2) = \sigma^2$
- Si sustituimos  $\hat{\sigma}^2$  arriba, tenemos estimadores insesgados para  $\text{Var}(\hat{\beta}_0)$  y  $\text{Var}(\hat{\beta}_1)$

$\hat{\sigma} = \sqrt{\hat{\sigma}^2}$  se llama el **error estándar de la regresión**

- $\mathbb{E}(\hat{\sigma}) \neq \sigma$  pero es consistente
- Es un estimado de la desviación estándar de los factores no observados que afectan a  $y$
- Propósito principal: Usar  $\hat{\sigma}$  para estimar las desviaciones estándar de  $\hat{\beta}_0$  y  $\hat{\beta}_1$

Dado que  $\text{desvest}(\hat{\beta}_1) = \frac{\sigma}{\sqrt{\text{SCT}_x}}$ , su estimador es

$$\text{errest}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\text{SCT}_x}}$$

- Se conoce como el **error estándar de  $\hat{\beta}_1$**
- Representa tanto a una variable aleatoria y como al estimado
- Nos da una idea de la precisión del estimador
- Sirven para construir estadísticos de prueba e intervalos de confianza

## 1.6 Regresión por el origen y sobre una constante

Si imponemos la restricción  $\beta_0 = 0$ , escogemos  $\tilde{\beta}_1$  tal que  $\tilde{y} = \tilde{\beta}_1 x$

$$\tilde{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

- Igual que  $\hat{\beta}_1$  pero con  $\bar{x} = 0$
- Al menos un  $x_i \neq 0$ , ¿por qué?
- La línea pasa por el origen ( $\tilde{y} = 0$  cuando  $x = 0$ )
- Si  $\beta_0 \neq 0$ ,  $\tilde{\beta}_1$  estará sesgado [ $\mathbb{E}(\tilde{\beta}_1) \neq \beta_1$ ]
- $R^2 < 0$  es posible ( $\tilde{y}$  ajusta mejor a  $y$  que  $\hat{y}$ )

Si imponemos la restricción  $\beta_1 = 0$ ,  $\tilde{\beta}_0 = \bar{y}$

- Produce la menor suma de desviaciones cuadradas
- Si  $\beta_1 \neq 0$ ,  $\tilde{\beta}_0$  estará sesgado [ $\mathbb{E}(\tilde{\beta}_0) \neq \beta_0$ ]

## 1.7 Resumen del modelo RLS

- Dada una muestra aleatoria, el método de MCO se usa para estimar los parámetros del intercepto y la pendiente del modelo poblacional
- Algebra de MCO: Podemos calcular valores ajustados, residuales y cambios predichos en variable dependiente para un cambio dado en la variable independiente
- Cuestiones prácticas:
  - Comportamiento de MCO cuando cambian las unidades de medición
  - Uso del logaritmo natural para modelar elasticidad constante y semi-elasticidad
- Bajo supuestos RLS.1 a RLS.4, los estimadores de MCO son insesgados
  - RLS.4 no se cumple si valores omitidos en  $u$  se correlacionan con  $x$
- Si suponemos homocedasticidad, podemos estimar las varianzas muestrales de MCO
- Regresión por el origen
- ¿Qué falta?
  - Eficiencia de MCO, hacer pruebas de hipótesis sobre los parámetros poblacionales, intervalos de confianza
  - RLS es un caso particular de RLM