

- Cuando una var. ordinal tiene muchos valores, no incluídas una dummy p/c/valor
 En ese caso: partamos la var. en categorías
- Vgr. ranking de la escuela: top10, r11-25, r26-40, r41-60, r61-100
 definir vars. dummy: igual a 1 cuando ranking caiga en rango
- ↳ gpo. base: escuelas con un ranking ~~en~~ debajo de 100
- ↳ podemos calcular el cambio porcentual exacto con $\exp(\beta_j) - 1$
- ↳ evaluar si partir var. en catégs ayuda: comparar R^2 's


Interacciones con Vars. Dummy

- Interacciones entre Vars.
- En ejemplo de género y edo. civil podemos agregar una ^{termino de} interacción \div $\begin{matrix} \text{mujer} \\ \text{casada} \end{matrix}$
 pl 1ª prueba de aceptación de pda del género
- $$\log(\text{salario}) = 0.321 - 0.11 \text{ mujer} + 0.213 \text{ casada} - 0.301 \text{ mujer} * \text{casada} + \dots$$

(0.100) (0.056) (0.055) (0.072) ← idéntico

* interacción estadísticamente significativa
- Podemos estimar la dif. de salario \div los 4 gpos. ← cuidado con selección de 0's y 1's
- ↳ h soltero (gpo. base): mujer=0, casada=0 \rightarrow intercepto: 0.321
- ↳ le casado: mujer=0, casada=1 \rightarrow intercepto: $0.321 + 0.213 = 0.534$
- ↳ es soltera: mujer=1, casada=0 \rightarrow intercepto: $0.321 - 0.11 = 0.211$
- ↳ es casada: mujer=1, casada=1 \rightarrow intercepto: $0.321 - 0.11 + 0.213 - 0.301 = 0.123$
- Dif. forma de obtener diferencias de salario \div combinaciones de género y edo. civil
- ↳ forma con interacc. \div dummies permite probar H_0 : $\begin{matrix} \text{diferencial de género no depende de edo civil} \\ \text{diferencial de edo civil no depende de género} \end{matrix}$
- ↳ forma g-1 catégs. mejor pl probar dif. salariales \div cualquier gpo. y gpo. base (h soltero)
- Modelar dif. Pendientes (herramienta poderosa)
- Incluir dif. vars. dummy permite tener dif. interceptos pl cualquier # de gpos.
- Pl dif. pendientes: interactuar vars. dummy con vars. indep. q no son dummies
- Vgr. dif. salarial etc. \div $\leq \frac{H}{N}$ pero ahora queremos probar si rendim. de educ es igual pl $\leq \frac{H}{N}$

$$\log(\text{salario}) = (\beta_0 + \delta_0 \text{ mujer}) + (\beta_1 + \delta_1 \text{ mujer}) \text{educ} + u$$



▶ p/H: mujer = 0 $\left\{ \begin{array}{l} \text{intercepto: } \beta_0 \\ \text{pendiente educ: } \beta_1 \end{array} \right.$

p/M: mujer = 1 $\left\{ \begin{array}{l} \text{intercepto: } \beta_0 + \delta_0 \\ \text{pendiente educ: } \beta_1 + \delta_1 \end{array} \right.$

▶ interpretación $\left\{ \begin{array}{l} \delta_0: \text{medida dif. en interceptos } \div \frac{H}{M} \\ \delta_1: \text{medida dif. en rendim. educ. } \div \frac{H}{M} \end{array} \right.$

M: gana menos q' H con poca educ y brecha se abre educ ↑

M: gana menos q' H con poca educ pero brecha se cierra educ ↑



- plantear define interacción mujer * educ y estimar

$$\log(\text{salario}) = \beta_0 + \delta_0 \text{mujer} + \beta_1 \text{educ} + \delta_1 \text{mujer} * \text{educ}$$

▶ $H_0: \delta_1 = 0 \rightarrow$ mismo rendim. a educ $\div \frac{H}{M}$, misma pendiente de $\log(\text{salario})$ wrt educ

▶ si $\delta_0 \neq 0 \rightarrow$ dif. interceptos, i.e. hay dif. salarial bajo H_0 pero es la misma p/dif. educ.

▶ $H_0: \delta_0 = 0, \delta_1 = 0$ (usamos prueba F) \rightarrow salarios promedio son iguales p/ $\frac{H}{M}$ con misma educ.

$$\begin{aligned} \text{Vgr } \log(\text{salario}) = & 0.389 - 0.227 \text{mujer} + 0.082 \text{educ} - 0.0056 \text{mujer} * \text{educ} + 0.029 \text{exper} - 0.00058 \text{exper}^2 + 0.032 \text{años} \\ & (0.117) \quad (0.168) \quad (0.008) \quad (0.0131) \quad (0.005) \quad (0.00011) \quad (0.007) \\ & \quad \quad \quad \uparrow \quad \quad \quad \uparrow \\ & \quad \quad \quad t = -1.35 \quad \quad \quad t = -0.43 \end{aligned}$$

▶ pendiente educ $\left\{ \begin{array}{l} H: 8.2\% \\ M: 0.082 - 0.0056 = 0.0764 = 7.6\% \end{array} \right.$

dif. -0.56% no signif. \rightarrow no evidencia en contra de H_0 (mismo rendim. educ.)

▶ mujer no indica si hay menor pago p/mujeres ceteris paribus

coef. mujer menos preciso x multicol $\div \frac{\text{mujer}}{\text{mujer} * \text{educ}}$

δ_0 medida dif. salarial $\div \frac{H}{M}$ cuando $\text{educ} = 0$ (pocas obs. en muestra)

plantear dif. salarial a $\text{educ} = 12.5$: cambiar $\text{mujer} * \text{educ}$ por $\text{mujer}(\text{educ} - 12.5)$

▶ p/H: $\delta_0 = 0, \delta_1 = 0$, estad. F = 34.33 con g.l. num = 2 y g.l. den = 518, valor-p ≈ 0

solo cuando $\text{educ} = 12.5$ \rightarrow $\text{mujer}(\text{educ} - 12.5)$

• Probar si Funciones de Regr. Varianza por Grupos.

- Queremos probar si mismo mod. de regr. describe las calif. de atletas univ. $\div \frac{H}{M}$

$$\text{GPA} = \beta_0 + \beta_1 \text{examen} + \beta_2 \text{preparacion} + \beta_3 \text{tothrs clase} + u$$

▶ p/dif. en interceptos: dummy p/ $\frac{H}{M}$

▶ p/dif en cualquier pendiente con base en género: interacción var. indep. con $\frac{H}{M}$

▶ aquí: queremos probar si hay cualquier dif. $\div \frac{H}{M} \Rightarrow$ $\left. \begin{array}{l} \text{intercepto} \\ \text{todas pendientes} \end{array} \right\}$ pueden ser dif. p/ $\frac{H}{M}$

$$GPA = \beta_0 + \delta_0 \text{ mujer} + \beta_1 \text{ examen} + \delta_1 \text{ mujer} \cdot \text{examen} + \beta_2 \text{ prepapet} + \delta_2 \text{ mujer} \cdot \text{prepapet} + \beta_3 \text{ totlers} + \delta_3 \text{ mujer} \cdot \text{totlers}$$

\uparrow dif. en intercepto \uparrow dif. en pend. examen

$H_0: \delta_0 = 0, \delta_1 = 0, \delta_2 = 0, \delta_3 = 0 \leftarrow GPA \text{ sigue mismo mod. } p| = H \text{ (con cualquier } g \neq 0 \text{ mod. esd.)}$

Vgr. (usad. no restringido)

$$GPA = 1.48 - 0.353 \text{ mujer} + 0.0011 \text{ examen} + 0.00075 \text{ mujer} \cdot \text{examen} - 0.00085 \text{ prepapet} - 0.00005 \text{ mujer} \cdot \text{prepapet} + 0.0023 \text{ totlers} - 0.00012 \text{ mujer} \cdot \text{totlers}$$

\uparrow $t \approx 2$

$n = 366$
 $R^2 = 0.406$
 $\bar{R}^2 = 0.394$

$p| \text{ estad. } F \text{ mod. restringido (sin mujer): } R^2 = 0.352, F \approx 8.44, \text{ valor-} p \approx 0 \Rightarrow \text{rechazamos } H_0$

$p| \text{ interpretar difs. tener en cuenta interacciones}$

Muena, $g \neq H$ en 0.353 solo cuando examen=0, prepapet=0, totlers=0

$$-0.353 + 0.00075(1,100) - 0.00055(10) - 0.00012(50) \approx 0.461$$

\uparrow \uparrow \uparrow
 sat prepa totlers

Muena $g \neq H$ a esos niveles de veridicd.

* $p| \text{ cualquier } \# \text{ de vars. indep. usamos la forma SCR del estad. } F$

En mod. gral.: k vars. indep., 1 intercepto, 2 gpos. $g \leq 2, H_0: \text{intercepto, todas pendientes son iguales}$

$$y = \beta_{g,0} + \beta_{g,1} x_1 + \beta_{g,2} x_2 + \dots + \beta_{g,k} x_k + u$$

$p| g=1, g=2$

$H_0: \text{misma } \beta \text{ p los 2 gpos involucra } k+1 \text{ restricciones (vgr GPA } k+1=4)$

mod. restringido (dummies de gpo. + k interaccs.): $(n-k-1) - (k+1) = n - 2(k+1)$ g.l. (vgr GPA $-2(4) = 358$)

Idea clave: SCR del mod. no restringido se puede obtener de 2 regs. (p|clgpo.)

$\uparrow SCR_1$ de estimar mod. p|gpo. $g=1$ con u_1 obs. ($u_1 = 90$ mujeres)

$\uparrow SCR_2$ " " " $g=2$ con u_2 obs. ($u_2 = 276$ hombres)

$\uparrow SCR_{sr} = SCR_1 + SCR_2$

$\uparrow SCR_r$ de estimar mod. como 1 solo gpo.

$$F = \frac{[SCR_r - (SCR_1 + SCR_2)]}{SCR_1 + SCR_2} \cdot \frac{[n - 2(k+1)]}{k+1}$$

estadístico F conocido como de Chow

Vgr. GPA

$SCR_r = 85.515, SCR_1 = 19.603 \text{ } u_1 = 90, SCR_2 = 58.752 \text{ } u_2 = 276 \Rightarrow SCR_{sr} = 19.603 + 58.752 = 78.355$

$$F = \frac{85.515 - 78.355}{78.355} \cdot \frac{358}{4} \approx 8.18$$

- solo valido bajo homos. ($\sigma_1^2 = \sigma_2^2$)

- forma R^2 solo se puede usar si se incluyen interacciones p| mod. s/restr.

- Limitación de la prueba de Chow: H_0 no permite cambios \div β pos.

Procedi permitir dif. en interceptos y probar por difs. en pendientes

2 formas \rightarrow incluir dummy p/ el gpo. y sus interacciones, y probar signif. conj. de las interaccs.

obtener una forma SCR del estadístico F en la q SCR_r se obtiene de una reg. q solo tiene un cambio de intercepto

$$F = \frac{[SCR_r - (SCR_1 + SCR_2)]}{SCR_1 + SCR_2} \cdot \frac{[n - 2(k+1)]}{k} \quad \text{-- probamos } k \text{ restricciones. no } k+1$$

- Si no se rechaza H_0 , el mejor modelo permite una dif. en interceptos

- Otros usos de dummy: ^{en series de tiempo} ejemplo estructural, estacionalidad, estimación por tramos

Mod. Lineal de Probabilidad (Var. Dep. Binaria)

- Hasta ahora var. dep. y la terna significado cuantitativo

- Podemos usar RLM p/ explicar un evento calitativo \rightarrow si, abito tiene prep
b y puede cambiar de 0 a 1, de 1 a 0 o no cambiar \rightarrow universitario construyó drogas
empresa adquirida por otra

- Interpretación de β_j 's cambia (ya no Δy ante $\Delta x = 1$ ceteris paribus)

- Si suponemos RLM-4 se cumple $(E(0|x_1, \dots, x_k) = 0): E(y|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$

- Como y es binaria, siempre se cumple $P(y=1|x) = E(y|x) \leftarrow$ prob. de éxito = valor esperado de y

$\therefore P(y=1|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k \leftarrow$ prob. de éxito $p(x) = P(y=1|x)$ es una func. lineal de las x_j

- ejemplo de mod. de respuesta binaria (otros logit, probit)

- $P(y=1|x)$ se llama la probabilidad de respuesta

- Como probabilidad \rightarrow suman 1, $P(y=0|x) = 1 - P(y=1|x)$ también es func. lineal de las x_j

- Mod. lineal de probab. \rightarrow RLM con y binaria x_j prob. de resp. es lineal en paráms. β_j

- En MRL, β_j mide el cambio en la prob. de éxito cuando cambia x_j ceteris paribus

$$\Delta P(y=1|x) = \beta_j \Delta x_j$$

- La mecánica de MCO es la misma q' antes

- Ec. estimada: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k$

- \hat{y} : prob. de éxito predicha

- $\hat{\beta}_0$: " " " cuando $x_j = 0$

- $\hat{\beta}_j$: cambio en prob. de éxito predicha cuando x_j en 1

- Vg. participación en fuerza laboral de mujeres en 1975 (FL)

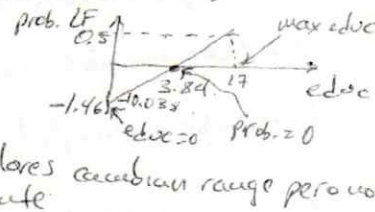
$$\text{enf lab} = 0.586 - 0.0034 \text{ ingresos} + 0.038 \text{ educ} + 0.037 \text{ exper} - 0.0006 \text{ exper}^2 - 0.016 \text{ edad} - 0.262 \text{ menor6} + 0.03 \text{ mayor6}$$

(0.154) (0.0014) (0.007) (0.006) (0.00018) (0.002) (0.034) (0.013)

↑ estadíst. signif. y signos esperados

$n = 753$ (428 f's)
 $R^2 = 0.264$
 años

interpretación: educ ↑ 10% → probab. de estar en FL ↑ $0.038(10) = 0.38$ ← incremento gde.
 si fijamos ingresos = 50, exper = 5, edad = 30, menor6 = 1, mayor6 = 0
 prob. 20 si educ < 3.84 pero en datos $\min(\text{educ}) = 5$
 $\text{max}(\text{educ}) = 17$ → probabilidad predicha de 0.5



interpretación: A ingresos = 10 (10k) → probab. en FL ↓ 0.034 ← efecto pequeño
 exper en cuadrado p/permitir q' tenga efecto decreciente en prob.
 $\Delta \text{enf lab} = 0.037 - 2(0.0006) \text{ exper} = 0.037 - 0.0012 \text{ exper}$ ceteris paribus
 ⇒ no efecto en prob. cuando $\text{exper} = \frac{0.037}{0.0012} = 32.5$ ← alto, solo 13 de 753 tienen exper > 32
 nro menor de 6 ↑ reduce prob. de particip. en 0.262

- MPL's son fáciles de estimar & interpretar

- Deficiencias del MPL

- ↑ p/ ciertos valores de vars. indep., predicciones < 0 o > 1 cuando prob.'s ∈ [0, 1]
 - ↑ efecto marginal constante: una prob. no puede estar relacionada linealmente a todos valores de vars. indep.
 - ↑ tiene heteroscedasticidad
- $\Delta \text{enf lab} = 0.262(\Delta \text{menor6}) = 0.048$ ← = 4
 no en muestra
- MPL útil sobre todo cerca de promedios de vars. indep., restringir atención a esos valores

- Forma de usar prob.'s predichas aún si < 0 o > 1 p/ predecir var. binaria

↑ \hat{y}_i : ~~esto~~ denota valores ajustados (puede q' haya < 0 y > 1)
 ↑ define valor predicho como: $\tilde{y}_i = 1$ si $\hat{y}_i \geq 0.5$ y $\tilde{y}_i = 0$ si $\hat{y}_i < 0.5$ → $\tilde{y}_i \in \{0, 1\}$ si \tilde{y}_i como y_i
 ↑ porcentaje correctamente predicho: medida de bondad de ajuste p/ vars. dep. binarias (comparar \tilde{y}_i vs y_i)

- MPL viola un supuesto G-M x₁ y es binaria y su varianza

$$\text{Var}(y|x) = E(y^2|x) - E(y|x)^2 = E(y|x) - E(y|x)^2 = p(x) - p(x)^2 = p(x)[1 - p(x)]$$

↑ donde $p(x) = \beta_0 + \beta_1 x + \dots + \beta_k x_k$ ⇒ Var. depende de x ⇒ hay heterosced en MPL
 ↑ no hay sesgo pero pruebas t y F no son válidas → corregir por est's pero en práctica similar

- Podemos incluir ~~variables~~ dummies como vars. indep. en modelos con vars. dep. dummies
 ↑ Coefs. miden la dif. predicha en la prob. en relación con el gpo. base

↑ arrest86 = 0.380 + ~~variables~~ + 0.17 mujer + 0.096 hispano
 prob. de arresto es 17% más alta p/ raza negra y raza blanca

Consideraciones Adicionales p/ Análisis de Políticas y Eval. de Programaciones

- Tener cuidado al evaluar programas x q' gral. en ciencias sociales q'pos. ^{control no asignados} _{trata. aleatoria}
- Incluir factores si pueden estar sistemáticamente relacionados con la var. indep. binaria de interés
 - ▶ Ej. discriminación en autorizaciones de créditos por raza
 - ▶ la aprobación depende de otros factores: ingreso, riqueza, calif. crediticia
 - ▶ necesitamos controlar por ellos si hay diferencias sistemáticas en ellos entre razas
 - ▶ $\text{aprobación} = \beta_0 + \beta_1 \text{no blanco} + \beta_2 \text{ingreso} + \beta_3 \text{riqueza} + \beta_4 \text{calidad} + \dots$ otros factores \leftarrow MPL
 - ▶ discriminación contra minorías si se rechaza $H_0: \beta_1 = 0$ en favor de $H_1: \beta_1 < 0$
- Problemas de auto-selección pueden hacer q' RLM esté sesgado por falta de controles suficientes
 - ▶ individuos se auto-seleccionan en comportamiento o programas \Rightarrow participación no aleatoria
 - ▶ Ej. individuos seleccionados p/ partic. en programa, pueden participar o no \leftarrow no aleatorio
 - ▶ se usa cuando indicador binario de participación puede relacionarse sistemáticamente con factores no observados
 - ▶ Ej. $y = \beta_0 + \beta_1 \text{participa} + u$ nos preocupa q' $E(u | \text{participa} = 1) \neq E(u | \text{participa} = 0) \leftarrow u$ depende de particip.
 - indep. var. es endógena, β_1 estará sesgada \leftarrow no encontramos verdadero efecto de partic. ^{podemos encontrar efectos espurios}
 - ▶ si factores correl. con partic. son observados, RLM mitiga el problema
 - ▶ " " " " " no son observados, RLM genera sesgo x falta de controles
 - en cuyo caso
 - datos panel
 - variables instrumentales
 - logit, probit

Interpretación de Resultados de Regr. con Vars. Dep. Discretas

- Cuando y es var. discreta de reg. con vars. Dep. Discretas
- Vgr: $\hat{hijos} = -1.997 + 0.175 \text{ edad} - 0.09 \text{ educ}$, $n = 4,361$, $R^2 = 0.56$ (mujeres de Botswana)
(0.024) (0.003) (0.006)
- MCO estima efectos de x_j sobre el valor esperado/promedio de y
- ↳ Bajo RLML a RLML.4, $E(y|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k \Rightarrow \beta_j$ efecto cat. par. de x_j ↑ sobre valor esp. de y
- ↳ Para una muestra dada, $\hat{E}(y|x) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \Rightarrow \hat{\beta}_j$ estimado de cómo promedio de y cambia cuando $\Delta x_j = 1$
- $\hat{\beta}_{educ} = -0.09$: estimamos q. fertilidad promedio cae 0.09 hijos dado 1 año más educ. si el mujer de un spo. de 100 tiene 1 A de educ, tendrá 9 niños menos ÷ ellas
- Agregar vars. dummy con y discreta no afecta interpretación
- ↳ Vgr: $\hat{hijos} = -2.071 + 0.174 \text{ edad} - 0.079 \text{ educ} - 0.362 \text{ electric}$, $n = 4,358$, $R^2 = 0.562$
(0.025) (0.003) (0.006) (0.068)
- ↳ Comparando 100 mujeres con electric. a 100 mujeres sin ella - y misma educ y edad - estimamos q. el 1er spo. tenga 36 niños menos
- RLML buena aprox. (lineal por rico) a efectos parciales sobre $E(y|x)$ por modelos: logit, probit, tobit, Poisson